# Assistente de banco de dados com GraphRAG: extração de conhecimento, grafo no Neo4j, recuperação híbrida e respostas fundamentadas

Autor 1, Autor 2, Autor 3, Autor 4, Autor 5, Autor 6

Instituição — Curso — Disciplina de Banco de Dados

`preencher com os nomes e o e-mail de cada integrante`

**Resumo**

Assistentes que respondem perguntas sobre bancos de dados precisam de mais que fluência: precisam de rastreabilidade. Este trabalho descreve um assistente que extrai conceitos e relações de nove capítulos de material didático sobre bancos de dados relacionais e SQL, armazena esse conhecimento em um grafo no Neo4j, recupera evidências por busca vetorial e por travessia de grafo, e gera respostas em português com citação literal por afirmação e um nível de sustentação calculado por regras, nunca pelo modelo. O sistema é avaliado em 15 perguntas: o modo híbrido (vetor e grafo) acerta 93% contra 60% da busca puramente vetorial, diferença concentrada nas perguntas que exigem dois ou mais relacionamentos (4 de 5 contra 1 de 5). Os três modos abstiveram-se corretamente em todas as cinco perguntas fora do corpus, e nenhuma das 43 respostas produzidas trouxe citação não verificada.

**Palavras-chave:** GraphRAG; KAG; Neo4j; recuperação híbrida; fundamentação de respostas; LLM.

## 1 Introdução

Modelos de linguagem respondem com fluência sobre bancos de dados e SQL, mas fluência não é rastreabilidade. Em contexto de ensino e de documentação técnica, uma resposta sem fonte verificável tem o mesmo valor que uma resposta ausente: não se pode conferir, e não se pode ensinar a conferir.

O projeto parte de uma pergunta prática — *a pergunta feita na interface consegue ser respondida com informação de dois documentos reais, com fonte verificável e visualização do grafo?* — e a trata como restrição de projeto, não como aspiração. O sistema foi construído em seis etapas encadeadas: extração de conhecimento do corpus, modelagem e ingestão em um grafo, recuperação híbrida, geração validada por LLM, interface com visualização e avaliação comparativa.

As contribuições são: (i) um contrato de extração com vocabulário fechado de rótulos, tipos de relação e propriedades, que permite validar automaticamente tudo o que entra no grafo; (ii) uma recuperação híbrida que soma busca vetorial multilíngue e travessia de grafo por fusão de ranks, com caminho mais curto e centralidade de grau; (iii) uma camada de geração em que o modelo *não* escreve Cypher: ele escolhe um plano em vocabulário fechado, e o sistema compila e valida a consulta; (iv) uma verificação de resposta que confere cada citação contra o texto original do corpus e calcula o nível de sustentação por regras explícitas; e (v) uma avaliação comparativa com 15 perguntas, medida nos três modos de recuperação.

# 2 Fundamentação e trabalhos relacionados

**RAG.** A geração aumentada por recuperação [1] combina um índice de passagens com um modelo gerador, reduzindo a dependência de conhecimento paramétrico. A limitação que motiva este trabalho é conhecida: a similaridade textual recupera passagens *parecidas* com a pergunta, não a cadeia de fatos que a responde.

**GraphRAG e KAG.** Abordagens que organizam o corpus em grafo [2] mostram ganho em perguntas que exigem agregar informação dispersa. A ideia central adotada aqui é a mesma — conhecimento estruturado como intermediário — com uma diferença de escopo: empregamos um grafo *curado e com evidência por aresta*, em vez de um grafo construído inteiramente pelo modelo, o que permite verificar cada afirmação contra o texto de origem.

**Fundamentação e abstenção.** A literatura sobre alucinação [4] distingue erros de fato de erros de formato e recomenda verificação externa. Nossa verificação é mecânica: a citação precisa existir literalmente no trecho, e a resposta que cita identificador inexistente é recusada.

**Fusão de rankings.** O *Reciprocal Rank Fusion* [3] combina rankings de recuperadores distintos sem calibrar escores, e é usado aqui para unir busca vetorial e evidências de grafo. O modelo de dados segue o grafo de propriedades [5], com três rótulos, relações tipadas, índices de texto e um índice vetorial nativo do Neo4j 5.

# 3 Corpus e extração de conhecimento

## 3.1 Corpus

Nove documentos em inglês, de material didático aberto de banco de dados relacional e da documentação do PostgreSQL, com autores, licença e URL preservados por documento: D01 (conceitos fundamentais), D02 (modelo ER), D03 (integridade e restrições), D04 (dependências funcionais), D05 (normalização), D06 (consulta e filtro), D07 (junções), D08 (funções de agregação) e D09 (modelo relacional).

O corpus foi dividido em **59 trechos**: 31 trechos de texto de página e 28 suplementos que transcrevem figuras essenciais, marcados com estado de transcrição e incertezas declaradas, para que nenhuma transcrição seja confundida com texto original. Cada trecho carrega documento, caminho de seção e URL de origem.

## 3.2 Extração

Três métodos, declarados por conceito e por relação:

| Arquivo | Método | Conceitos | Relações |
|---|---|---|---|
| `rule-knowledge-union-v2` | regras sobre o texto, com curadoria | 79 | 5 |
| `model-knowledge-union-v3` | proposta de LLM local, com curadoria | 20 | 11 |
| `manual-source-review-v1` | curadoria manual assistida por IA | 5 | 0 |

Os três arquivos somam **93 conceitos únicos** e **16 triplas semânticas**; com a amostra manual opcional, **23 triplas**. Cada conceito tem nome canônico em inglês, nome em português, aliases, descrição, estado de revisão e as citações que o sustentam. Cada relação carrega os identificadores dos trechos de evidência e as citações literais correspondentes: a unidade de verificação de todo o sistema é a aresta com evidência, não o documento.

Identificadores são estáveis e independentes do nome (`C_...` para conceitos, `D03_C001`

para trechos, D0n para documentos). Nome nunca é identidade, o que evita fundir conceitos por semelhança de rótulo.

### 3.3 Limites desta etapa

A cobertura de relações é o gargalo do projeto. Vinte e três triplas semânticas para 93 conceitos significam que a maioria dos conceitos não participa de nenhum caminho multi-hop. Dos três métodos, apenas o de regras e o de LLM produzem relações, e nenhum foi validado por revisão humana independente: o registro é de aprovação do próprio grupo.

## 4 Modelagem e ingestão no Neo4j

### 4.1 Modelo

Três rótulos, cada um com identificador único e estável, e relações estruturais separadas das semânticas. Estruturais: CONTAINS (Documento para Trecho), SUPPLEMENTS (figura para trecho-pai) e MENTIONS (Trecho para Conceito). Semânticas, em vocabulário fechado de 14 tipos: IS_A, SUPPORTS, REQUIRES, GOVERNS, TYPICALLY_USED_IN, COMBINES, HAS_FORM, PRESERVES, RETRIEVES, FILTERS, GROUPS, AGGREGATES, EVALUATED_BEFORE e REMOVES_DUPLICATES.

O Neo4j armazena apenas valores simples, então objetos e listas aninhadas (evidências, licença, caminhos de seção) ficam como texto JSON em propriedades terminadas em _json, o que mantém a ingestão idempotente e preserva a citação literal.

### 4.2 Ingestão e garantias

A ingestão roda em uma única transação, com MERGE por identificador e SET += para propriedades, de modo que uma segunda execução não duplica nem apaga — inclusive propriedades criadas por outras etapas, como o vetor de *embedding*. Três restrições de unicidade e sete índices, entre eles um índice de texto sobre nomes em inglês, português e aliases que ignora acentos.

| Carga | Document | Chunk | Concept | MENTIONS | Rel. semânticas |
|---|---|---|---|---|---|
| 3 arquivos principais | 9 | 59 | 93 | 130 | 16 |
| com a amostra opcional | 9 | 59 | 93 | 134 | 23 |

Uma verificação automática confere o banco contra os arquivos entregues: contagens, ausência de referência inválida, presença de caminho de dois saltos com evidência por aresta e ausência de REQUIRES onde a fonte diz “tipicamente”.

## 5 Recuperação híbrida

### 5.1 Embeddings

Modelo paraphrase-multilingual-MiniLM-L12-v2, 384 dimensões, similaridade de cosseno. A escolha responde ao descompasso de idioma do projeto: o corpus é em inglês e as perguntas em português. Os 59 vetores estão pré-computados e versionados, e o mesmo modelo cria um índice vetorial nativo no Neo4j.

## 5.2 Componentes

1. **Vinculação de conceitos.** A pergunta é comparada com os 93 conceitos (nome em inglês, em português e aliases) após normalização sem acento e sem plural.
2. **Travessia multi-hop.** A partir das sementes, o sistema percorre as relações semânticas até um orçamento de saltos, carregando de cada aresta a citação que a sustenta.
3. **Caminho mais curto.** Quando a pergunta envolve dois conceitos, o caminho mínimo entre eles define a cadeia a percorrer — é o que liga documentos distintos, como D03 e D07 na cadeia integridade referencial, chave estrangeira, junção, junção externa, junção externa à esquerda.
4. **Centralidade de grau.** Pondera os conceitos do subgrafo para priorizar nós de maior conectividade contextual.
5. **Fusão por RRF.** Os rankings vetorial e de grafo são combinados por uma soma de recíprocos das posições, com constante 60, o que soma os dois canais sem calibrar escores.

## 5.3 Modos de recuperação

| Modo | Recuperação | Depende de |
|---|---|---|
| `vector` | busca vetorial sobre os 59 trechos (*top_k* = 5) | embeddings |
| `hybrid` | vetorial, travessia, caminho mais curto e centralidade, por RRF | idem |
| `graph` | plano de consulta Cypher validado, executado no Neo4j | grafo ingerido |

# 6 Geração validada com LLM

## 6.1 O modelo não escreve a consulta

O modelo recebe a pergunta e devolve um *plano* em vocabulário fechado: nó inicial, direção, tipos de relação e limite. O sistema compila esse plano em uma única consulta de caminho, parametrizada. Toda identificação — rótulo, tipo, propriedade, identificador — é conferida contra listas fixas antes de chegar ao Cypher, de modo que texto do modelo nunca vira sintaxe.

O orçamento de saltos é um único número (`DEFAULT_MAX_HOPS = 4`) compartilhado pelo validador, pelo executor e pelos adaptadores. Cypher livre existe como alternativa, validado por regras: uma única instrução, nenhum comentário, nenhuma string literal (valores só por parâmetro), nenhum comando de escrita ou procedimento de extensão, todo padrão de nó rotulado, `RETURN` projetado e `LIMIT` obrigatório. Um conjunto de 38 casos de contorno (32 recusas obrigatórias, 5 controles e um limite conhecido) é executado a cada rodada de testes.

## 6.2 Resposta fundamentada

O modelo recebe as evidências com identificadores (E1 … En), nunca URLs, e devolve afirmações, cada uma citando identificadores. O sistema então recusa citação de identificador inexistente, confere se a citação existe *literalmente* no texto do trecho, descarta afirmações sem evidência, resolve cada citação em trecho, seção e URL, e calcula o nível de sustentação por regras.

| Nível | Critério |
|---|---|
| `high` | citações aceitas, de ao menos dois trechos e dois documentos |
| `medium` | um único trecho, um único documento, ou citação não conferida |
| `low` | evidência pendente ou sinalizada, ou afirmação descartada |
| `insufficient` | nenhuma afirmação sobreviveu à verificação |

O modelo é proibido de informar confiança: o nível é calculado fora dele, sobre as citações efetivamente devolvidas.

# 7 Interface e visualização

A aplicação apresenta, na mesma tela: a resposta em português; cada afirmação com o marcador da evidência que a sustenta; o painel de sustentação (nível, cobertura, trechos, documentos, citações não verificadas e as razões); o subgrafo percorrido; as fontes com link; as citações literais; e a consulta Cypher executada com seus parâmetros.

O subgrafo é desenhado em SVG com layout por distância na travessia, determinístico: a mesma resposta sempre produz a mesma figura. No modo híbrido, o grafo é montado a partir das relações que o pacote de evidências realmente usou, e a tela informa canais e origens em vez de exibir um Cypher que não foi executado.

Como a geração local leva de um a dois minutos por resposta, a execução é assíncrona: a requisição devolve um identificador de trabalho e a página acompanha o passo corrente. Estados terminais são distintos de propósito — respondido, sem correspondência no grafo, resposta recusada pela verificação e falha de serviço — e nenhum deles é suavizado em texto.

# 8 Avaliação

## 8.1 Desenho

Quinze perguntas em três grupos de cinco: conceituais, multi-hop e sem resposta no corpus. Cada pergunta tem gabarito de conceitos e de documentos, *derivado das evidências das relações do grafo* — nunca das respostas do sistema. As perguntas multi-hop foram escolhidas entre caminhos que existem, e um teste automatizado confere que cada par consecutivo da cadeia tem aresta de um salto.

O critério de acerto é mecânico e idêntico nos três modos: pergunta com resposta exige resposta entregue, ao menos um documento esperado entre as fontes citadas e nenhuma citação não verificada; pergunta sem resposta exige abstenção. O mesmo modelo, prompt, orçamento de tokens e verificador são usados; muda apenas a recuperação.

## 8.2 Resultados

Quarenta e cinco execuções (15 perguntas em 3 modos), 2 falhas de verificação e nenhuma citação não verificada.

| Modo | Corretas | Acerto | Doc. esperado | Abstenção | Nível alto | Tempo |
|---|---|---|---|---|---|---|
| `vector` | 9/15 | 60% | 4/10 | 5/5 | 0 | 65 s |
| `hybrid` | 14/15 | **93%** | 9/10 | 5/5 | 5 | 71 s |
| `graph` | 14/15 | **93%** | 9/10 | 5/5 | 1 | 51 s |

| Grupo | `vector` | `hybrid` | `graph` |
|---|---|---|---|
| conceitual (5) | 3/5 | 5/5 | 4/5 |
| multi-hop (5) | 1/5 | 4/5 | 5/5 |
| sem resposta (5) | 5/5 | 5/5 | 5/5 |

### 8.3 Análise

**A diferença aparece exatamente onde a arquitetura promete.** No grupo multi-hop o baseline vetorial acerta 1 de 5; o híbrido, 4 de 5; o modo de plano, 5 de 5. Em três dessas perguntas o baseline recebeu trechos sobre o assunto e mesmo assim absteve-se: um trecho isolado não responde a uma pergunta que exige ligar dois conceitos. É precisamente o que a travessia do grafo acrescenta, e é a evidência que justifica a complexidade da arquitetura.

**Abstenção é 5 de 5 nos três modos.** Nenhum modo respondeu pergunta fora do corpus. No modo de plano a recusa acontece antes do modelo: se nenhum conceito da pergunta existe no grafo, o modelo não é chamado, o que também explica o menor tempo médio.

**O modo de plano iguala o acerto e troca diversidade por velocidade.** Ele produz uma única resposta `high`, contra cinco do híbrido, porque um caminho tende a citar um documento só.

**Duas falhas de verificação, do mesmo tipo.** Em duas células o modelo devolveu abstenção acompanhada de afirmações com evidência, e o verificador recusou. A resposta foi barrada em vez de entregue inconsistente; para o critério, conta como não acerto.

## 9 Ameaças à validade

**Cobertura da extração.** Vinte e três relações semânticas condicionam tudo: a maior parte das perguntas multi-hop possíveis não tem caminho no grafo, e as perguntas da avaliação usam praticamente todos os caminhos disponíveis.

**Circularidade parcial do gabarito.** Os documentos esperados vêm das evidências do grafo, o que favorece os modos que usam o grafo por construção. O critério também não julga a correção do *texto* da resposta, apenas a fonte citada e a literalidade da citação.

**Tamanho da amostra.** Quinze perguntas significam 6,7 pontos percentuais por pergunta, e cada célula foi executada uma única vez. A mesma pergunta, com a mesma consulta, já produziu níveis diferentes em execuções repetidas, porque o nível depende de quais evidências o modelo cita.

**Uma correção de gabarito declarada.** A pergunta Q09 passou a aceitar o documento D08 além do D06 depois da primeira rodada, porque D08 também explica `WHERE`. Sem a correção, `vector` teria 8/15 e os outros dois 13/15: a conclusão não muda.

**Revisão humana.** Nenhuma etapa teve revisão humana independente dos fatos extraídos, o que enfraquece a premissa de que as arestas do grafo estão corretas.

**Um modelo, uma máquina.** `qwen3:8b` em CPU parcial; outro modelo mudaria os números. A verificação das citações, não.

## 10 Conclusão e continuidade

O sistema cumpre o objetivo inicial: uma pergunta em português é respondida com informação de documentos distintos, com citação literal por afirmação, nível de sustentação calculado por regras e visualização do subgrafo percorrido. A comparação com RAG puramente vetorial

mostra ganho concentrado nas perguntas que exigem mais de um relacionamento — 4 de 5 contra 1 de 5 — e nenhum modo respondeu pergunta fora do corpus.

Três continuidades se destacam: ampliar a extração de relações, que é o fator limitante de cobertura; repetir a avaliação três vezes por célula e reportar média e dispersão; e substituir o gabarito derivado do grafo por um gabarito anotado por pessoa, o que permitiria julgar a correção do texto e não apenas a procedência da fonte.

# Referências


[1] LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[2] EDGE, D. et al. From local to global: a graph RAG approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*, 2024.

[3] CORMACK, G. V.; CLARKE, C. L. A.; BUETTCHER, S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In: *Proceedings of SIGIR*, 2009. p. 758–759.

[4] JI, Z. et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, v. 55, n. 12, p. 1–38, 2023.

[5] ROBINSON, I.; WEBBER, J.; EIFREM, E. *Graph Databases*. 2. ed. Sebastopol: O'Reilly Media, 2015.