Assistente de banco de dados com GraphRAG: extração de conhecimento, grafo no Neo4j, recuperação híbrida e respostas fundamentadas

João Pedro Coutinho Nóbrega[1], **Lucas Bezerra Ribeiro Coutinho**[1], **Jefferson Coutinho da Cunha Filho**[1], **Matheus Oliveira Aquino Leal Rodrigues**[1], **Ramon Sávio Fontes Rocha**[1], **Adijair Pinto Viana Gonçalves de Araújo**[1]

[1]Centro Universitário de João Pessoa (UNIPÊ)
Curso de Bacharelado em Ciência da Computação
Disciplina: Tendências em Ciência da Computação
j.nobrega@cs.unipe.edu.br, l.coutinho@cs.unipe.edu.br
jefferson.filho@cs.unipe.edu.br, ramon.savio@cs.unipe.edu.br
matheus.rodrigues@cs.unipe.edu.br, adijair.araujo@cs.unipe.edu.br

Abstract. *Assistants that answer questions about databases need more than fluency: they need traceability. This work describes an assistant that extracts concepts and relations from nine chapters of open didactic material on relational databases and SQL, stores that knowledge in a Neo4j graph, retrieves evidence through vector search and graph traversal, and generates answers in Portuguese with a literal citation per statement and a support level computed by rules, never by the model. The system is evaluated on 15 questions: the hybrid mode (vector plus graph) answers 93% correctly, against 60% for pure vector search, a difference concentrated on questions that require two or more relationships (4 of 5 against 1 of 5). All three modes abstained correctly on the five questions outside the corpus, and none of the 43 answers produced carried an unverified citation.*

Resumo. *Assistentes que respondem perguntas sobre bancos de dados precisam de mais que fluência: precisam de rastreabilidade. Este trabalho descreve um assistente que extrai conceitos e relações de nove capítulos de material didático sobre bancos de dados relacionais e SQL, armazena esse conhecimento em um grafo no Neo4j, recupera evidências por busca vetorial e por travessia de grafo, e gera respostas em português com citação literal por afirmação e um nível de sustentação calculado por regras, nunca pelo modelo. O sistema é avaliado em 15 perguntas: o modo híbrido (vetor e grafo) acerta 93% contra 60% da busca puramente vetorial, diferença concentrada nas perguntas que exigem dois ou mais relacionamentos (4 de 5 contra 1 de 5). Os três modos abstiveram-se corretamente em todas as cinco perguntas fora do corpus, e nenhuma das 43 respostas produzidas trouxe citação não verificada.*

Palavras-chave: *GraphRAG; KAG; Neo4j; recuperação híbrida; fundamentação de respostas; LLM.*

1. Introdução

Modelos de linguagem respondem com fluência sobre bancos de dados e SQL, mas fluência não é rastreabilidade. Em contexto de ensino e de documentação técnica, uma resposta

sem fonte verificável tem o mesmo valor que uma resposta ausente: não se pode conferir, e não se pode ensinar a conferir.

O projeto parte de uma pergunta prática — *a pergunta feita na interface consegue ser respondida com informação de dois documentos reais, com fonte verificável e visualização do grafo?* — e a trata como restrição de projeto, não como aspiração. O sistema foi construído em seis etapas encadeadas: extração de conhecimento do corpus, modelagem e ingestão em um grafo, recuperação híbrida, geração validada por LLM, interface com visualização e avaliação comparativa.

As contribuições são: (i) um contrato de extração com vocabulário fechado de rótulos, tipos de relação e propriedades, que permite validar automaticamente tudo o que entra no grafo; (ii) uma recuperação híbrida que soma busca vetorial multilíngue e travessia de grafo por fusão de ranks, com caminho mais curto e centralidade de grau; (iii) uma camada de geração em que o modelo *não* escreve Cypher: ele escolhe um plano em vocabulário fechado, e o sistema compila e valida a consulta; (iv) uma verificação de resposta que confere cada citação contra o texto original do corpus e calcula o nível de sustentação por regras explícitas; e (v) uma avaliação comparativa com 15 perguntas, medida nos três modos de recuperação.

2. Fundamentação e trabalhos relacionados

RAG. A geração aumentada por recuperação [1] combina um índice de passagens com um modelo gerador, reduzindo a dependência de conhecimento paramétrico. A limitação que motiva este trabalho é conhecida: a similaridade textual recupera passagens *parecidas* com a pergunta, não a cadeia de fatos que a responde.

GraphRAG e KAG. Abordagens que organizam o corpus em grafo [2] mostram ganho em perguntas que exigem agregar informação dispersa. A ideia central adotada aqui é a mesma — conhecimento estruturado como intermediário — com uma diferença de escopo: empregamos um grafo *curado e com evidência por aresta*, em vez de um grafo construído inteiramente pelo modelo, o que permite verificar cada afirmação contra o texto de origem.

Fundamentação e abstenção. A literatura sobre alucinação [4] distingue erros de fato de erros de formato e recomenda verificação externa. Nossa verificação é mecânica: a citação precisa existir literalmente no trecho, e a resposta que cita identificador inexistente é recusada.

Fusão de rankings. O *Reciprocal Rank Fusion* [3] combina rankings de recuperadores distintos sem calibrar escores, e é usado aqui para unir busca vetorial e evidências de grafo. O modelo de dados segue o grafo de propriedades [5], com três rótulos, relações tipadas, índices de texto e um índice vetorial nativo do Neo4j 5.

3. Corpus e extração de conhecimento

3.1. Corpus

Nove documentos em inglês, de material didático aberto de banco de dados relacional e da documentação do PostgreSQL, com autores, licença e URL preservados por documento: D01 (conceitos fundamentais), D02 (modelo ER), D03 (integridade e restrições), D04

(dependências funcionais), D05 (normalização), D06 (consulta e filtro), D07 (junções), D08 (funções de agregação) e D09 (modelo relacional).

O corpus foi dividido em **59 trechos**: 31 trechos de texto de página e 28 suplementos que transcrevem figuras essenciais, marcados com estado de transcrição e incertezas declaradas, para que nenhuma transcrição seja confundida com texto original. Cada trecho carrega documento, caminho de seção e URL de origem.

3.2. Extração

Três métodos, declarados por conceito e por relação (Tabela 1):

Tabela 1. Métodos de extração e volume por arquivo.

Arquivo	Método	Conceitos	Relações
`rule-knowledge-union-v2`	regras sobre o texto, com curadoria	79	5
`model-knowledge-union-v3`	proposta de LLM local, com curadoria	20	11
`manual-source-review-v1`	curadoria manual assistida por IA	5	0

Os três arquivos somam **93 conceitos únicos** e **16 triplas semânticas**; com a amostra manual opcional, **23 triplas**. Cada conceito tem nome canônico em inglês, nome em português, aliases, descrição, estado de revisão e as citações que o sustentam. Cada relação carrega os identificadores dos trechos de evidência e as citações literais correspondentes: a unidade de verificação de todo o sistema é a aresta com evidência, não o documento.

Identificadores são estáveis e independentes do nome (`C_...` para conceitos, `D03_C001` para trechos, `D0n` para documentos). Nome nunca é identidade, o que evita fundir conceitos por semelhança de rótulo.

3.3. Limites desta etapa

A cobertura de relações é o gargalo do projeto. Vinte e três triplas semânticas para 93 conceitos significam que a maioria dos conceitos não participa de nenhum caminho multi-hop. Dos três métodos, apenas o de regras e o de LLM produzem relações, e nenhum foi validado por revisão humana independente: o registro é de aprovação do próprio grupo.

4. Modelagem e ingestão no Neo4j

4.1. Modelo

Três rótulos, cada um com identificador único e estável, e relações estruturais separadas das semânticas. Estruturais: `CONTAINS` (Documento para Trecho), `SUPPLEMENTS` (figura para trecho-pai) e `MENTIONS` (Trecho para Conceito). Semânticas, em vocabulário fechado de 14 tipos: `IS_A`, `SUPPORTS`, `REQUIRES`, `GOVERNS`, `TYPICALLY_USED_IN`, `COMBINES`, `HAS_FORM`, `PRESERVES`, `RETRIEVES`, `FILTERS`, `GROUPS`, `AGGREGATES`, `EVALUATED_BEFORE` e `REMOVES_DUPLICATES`.

O Neo4j armazena apenas valores simples, então objetos e listas aninhadas (evidências, licença, caminhos de seção) ficam como texto JSON em propriedades terminadas em `_json`, o que mantém a ingestão idempotente e preserva a citação literal.

4.2. Ingestão e garantias

A ingestão roda em uma única transação, com `MERGE` por identificador e `SET +=` para propriedades, de modo que uma segunda execução não duplica nem apaga — inclusive propriedades criadas por outras etapas, como o vetor de *embedding*. Três restrições de unicidade, quatro índices de propriedade, um índice vetorial e um índice de texto sobre nomes em inglês, português e aliases que ignora acentos. Esse índice de texto não é decorativo: é ele que liga a pergunta aos conceitos quando nenhum nome casa palavra por palavra, e é o que a tela usa para sugerir um termo que existe no grafo. A Tabela 2 resume as contagens por carga.

Tabela 2. Contagens por carga no grafo.

Carga	Document	Chunk	Concept	MENTIONS	Rel. semânticas
3 arquivos principais	9	59	93	130	16
com a amostra opcional	9	59	93	134	23

Uma verificação automática confere o banco contra os arquivos entregues: contagens, ausência de referência inválida, presença de caminho de dois saltos com evidência por aresta e ausência de `REQUIRES` onde a fonte diz "tipicamente".

5. Recuperação híbrida

5.1. Embeddings

Modelo `paraphrase-multilingual-MiniLM-L12-v2`, 384 dimensões, similaridade de cosseno. A escolha responde ao descompasso de idioma do projeto: o corpus é em inglês e as perguntas em português. Os 59 vetores estão pré-computados e versionados, e o mesmo modelo cria um índice vetorial nativo no Neo4j.

5.2. Componentes

1. **Vinculação de conceitos.** A pergunta é comparada com os 93 conceitos (nome em inglês, em português e aliases) após normalização sem acento e sem plural.
2. **Travessia multi-hop.** A partir das sementes, o sistema percorre as relações semânticas até um orçamento de saltos, carregando de cada aresta a citação que a sustenta.
3. **Caminho mais curto.** Quando a pergunta envolve dois conceitos, o caminho mínimo entre eles define a cadeia a percorrer — é o que liga documentos distintos, como D03 e D07 na cadeia integridade referencial, chave estrangeira, junção, junção externa, junção externa à esquerda.
4. **Centralidade de grau.** Pondera os conceitos do subgrafo para priorizar nós de maior conectividade contextual.
5. **Fusão por RRF.** Os rankings vetorial e de grafo são combinados por uma soma de recíprocos das posições, com constante 60, o que soma os dois canais sem calibrar escores.

5.3. Modos de recuperação

Os três modos avaliados diferem apenas na recuperação (Tabela 3).

Tabela 3. Modos de recuperação comparados na avaliação.

Modo	Recuperação	Depende de
`vector`	busca vetorial sobre os 59 trechos (*top_k* = 5)	embeddings
`hybrid`	vetorial, travessia, caminho mais curto e centralidade, por RRF	idem
`graph`	plano de consulta Cypher validado, executado no Neo4j	grafo ingerido

6. Geração validada com LLM

6.1. O modelo não escreve a consulta

O modelo recebe a pergunta e devolve um *plano* em vocabulário fechado: nó inicial, direção, tipos de relação e limite. O sistema compila esse plano em uma única consulta de caminho, parametrizada. Toda identificação — rótulo, tipo, propriedade, identificador — é conferida contra listas fixas antes de chegar ao Cypher, de modo que texto do modelo nunca vira sintaxe.

O orçamento de saltos é um único número (`DEFAULT_MAX_HOPS = 4`) compartilhado pelo validador, pelo executor e pelos adaptadores. Cypher livre existe como alternativa, validado por regras: uma única instrução, nenhum comentário, nenhuma string literal (valores só por parâmetro), nenhum comando de escrita ou procedimento de extensão, todo padrão de nó rotulado, `RETURN` projetado e `LIMIT` obrigatório. Um conjunto de 38 casos de contorno (32 recusas obrigatórias, 5 controles e um limite conhecido) é executado a cada rodada de testes.

6.2. Resposta fundamentada

O modelo recebe as evidências com identificadores (E1 … En), nunca URLs, e devolve afirmações, cada uma citando identificadores. O sistema então recusa citação de identificador inexistente, confere se a citação existe *literalmente* no texto do trecho, descarta afirmações sem evidência, resolve cada citação em trecho, seção e URL, e calcula o nível de sustentação por regras.

Tabela 4. Regras do nível de sustentação.

Nível	Critério
`high`	citações aceitas, de ao menos dois trechos e dois documentos
`medium`	um único trecho, um único documento, ou citação não conferida
`low`	evidência pendente ou sinalizada, ou afirmação descartada
`insufficient`	nenhuma afirmação sobreviveu à verificação

O modelo é proibido de informar confiança: o nível é calculado fora dele, sobre as citações efetivamente devolvidas.

7. Interface e visualização

A aplicação apresenta, na mesma tela: a resposta em português; cada afirmação com o marcador da evidência que a sustenta; o painel de sustentação (nível, cobertura, trechos, documentos, citações não verificadas e as razões); o subgrafo percorrido; as fontes com link; as citações literais; e a consulta Cypher executada com seus parâmetros.

O subgrafo é desenhado em SVG com layout por distância na travessia, determinístico: a mesma resposta sempre produz a mesma figura. No modo híbrido, o grafo é montado a partir das relações que o pacote de evidências realmente usou, e a tela informa canais e origens em vez de exibir um Cypher que não foi executado.

Como a geração local leva de um a dois minutos por resposta, a execução é assíncrona: a requisição devolve um identificador de trabalho e a página acompanha o passo corrente. Estados terminais são distintos de propósito — respondido, sem correspondência no grafo, resposta recusada pela verificação e falha de serviço — e nenhum deles é suavizado em texto.

8. Avaliação

8.1. Desenho

Quinze perguntas em três grupos de cinco: conceituais, multi-hop e sem resposta no corpus. Cada pergunta tem gabarito de conceitos e de documentos, *derivado das evidências das relações do grafo* — nunca das respostas do sistema. As perguntas multi-hop foram escolhidas entre caminhos que existem, e um teste automatizado confere que cada par consecutivo da cadeia tem aresta de um salto.

O critério de acerto é mecânico e idêntico nos três modos: pergunta com resposta exige resposta entregue, ao menos um documento esperado entre as fontes citadas e nenhuma citação não verificada; pergunta sem resposta exige abstenção. O mesmo modelo, prompt, orçamento de tokens e verificador são usados; muda apenas a recuperação.

8.2. Resultados

Quarenta e cinco execuções (15 perguntas em 3 modos), 2 falhas de verificação e nenhuma citação não verificada (Tabela 5).

Tabela 5. Resultados das 45 execuções, 15 perguntas em 3 modos.

Modo	Corretas	Acerto	Doc. esperado	Abstenção	Nível alto	Tempo
`vector`	9/15	60%	4/10	5/5	0	65 s
`hybrid`	14/15	**93%**	9/10	5/5	5	71 s
`graph`	14/15	**93%**	9/10	5/5	1	51 s

O acerto por grupo de pergunta está na Tabela 6.

Tabela 6. Acerto por grupo de pergunta.

Grupo	`vector`	`hybrid`	`graph`
conceitual (5)	3/5	5/5	4/5
multi-hop (5)	1/5	4/5	5/5
sem resposta (5)	5/5	5/5	5/5

8.3. Análise

A diferença aparece exatamente onde a arquitetura promete. No grupo multi-hop o baseline vetorial acerta 1 de 5; o híbrido, 4 de 5; o modo de plano, 5 de 5. Em três dessas perguntas o baseline recebeu trechos sobre o assunto e mesmo assim absteve-se: um trecho isolado não responde a uma pergunta que exige ligar dois conceitos. É precisamente o que a travessia do grafo acrescenta, e é a evidência que justifica a complexidade da arquitetura.

Abstenção é 5 de 5 nos três modos. Nenhum modo respondeu pergunta fora do corpus. No modo de plano a recusa acontece antes do modelo: se nenhum conceito da pergunta existe no grafo, o modelo não é chamado, o que também explica o menor tempo médio.

O modo de plano iguala o acerto e troca diversidade por velocidade. Ele produz uma única resposta `high`, contra cinco do híbrido, porque um caminho tende a citar um documento só.

Duas falhas de verificação, do mesmo tipo. Em duas células o modelo devolveu abstenção acompanhada de afirmações com evidência, e o verificador recusou. A resposta foi barrada em vez de entregue inconsistente; para o critério, conta como não acerto.

9. Ameaças à validade

Cobertura da extração. Vinte e três relações semânticas condicionam tudo: a maior parte das perguntas multi-hop possíveis não tem caminho no grafo, e as perguntas da avaliação usam praticamente todos os caminhos disponíveis.

Circularidade parcial do gabarito. Os documentos esperados vêm das evidências do grafo, o que favorece os modos que usam o grafo por construção. O critério também não julga a correção do *texto* da resposta, apenas a fonte citada e a literalidade da citação.

Tamanho da amostra. Quinze perguntas significam 6,7 pontos percentuais por pergunta, e cada célula foi executada uma única vez. A mesma pergunta, com a mesma consulta, já produziu níveis diferentes em execuções repetidas, porque o nível depende de quais evidências o modelo cita.

Uma correção de gabarito declarada. A pergunta Q09 passou a aceitar o documento D08 além do D06 depois da primeira rodada, porque D08 também explica `WHERE`. Sem a correção, `vector` teria 8/15 e os outros dois 13/15: a conclusão não muda.

Revisão humana. Nenhuma etapa teve revisão humana independente dos fatos extraídos, o que enfraquece a premissa de que as arestas do grafo estão corretas.

Um modelo, uma máquina. `qwen3:8b` em CPU parcial; outro modelo mudaria os números. A verificação das citações, não.

10. Conclusão e continuidade

O sistema cumpre o objetivo inicial: uma pergunta em português é respondida com informação de documentos distintos, com citação literal por afirmação, nível de sustentação calculado por regras e visualização do subgrafo percorrido. A comparação com RAG

puramente vetorial mostra ganho concentrado nas perguntas que exigem mais de um relacionamento — 4 de 5 contra 1 de 5 — e nenhum modo respondeu pergunta fora do corpus.

Três continuidades se destacam: ampliar a extração de relações, que é o fator limitante de cobertura; repetir a avaliação três vezes por célula e reportar média e dispersão; e substituir o gabarito derivado do grafo por um gabarito anotado por pessoa, o que permitiria julgar a correção do texto e não apenas a procedência da fonte.

Referências

[1] LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[2] EDGE, D. et al. From local to global: a graph RAG approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*, 2024.

[3] CORMACK, G. V.; CLARKE, C. L. A.; BUETTCHER, S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In: *Proceedings of SIGIR*, 2009. p. 758–759.

[4] JI, Z. et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, v. 55, n. 12, p. 1–38, 2023.

[5] ROBINSON, I.; WEBBER, J.; EIFREM, E. *Graph Databases*. 2. ed. Sebastopol: O'Reilly Media, 2015.